## Weka[34] LWL 源代码分析

作者: Koala++/屈伟

看了笨笨的 Blog, 想起来 Ng Andrew 说过他的导师 Michael Jordan(与那个篮球明星同名) 最喜欢的就是 LWL 算法。

Locally weighted learning. Uses an instance-based algorithm to assign instance weights which are then used by a specified WeightedInstancesHandler. Can do classification (e.g. using naive Bayes) or regression (e.g. using linear regression)

Locally weighted learning(LWL) , 用 基 于 样 本 的 算 法 用 - 个 特 定 的 weightedInstancesHandler 赋给样本权重。可以进行分类或是回归。

我也大概看了一下它是如何来实现的。

它是继承自 SingleClassifierEnhancer 类,在它的构造函数中:

```
public LWL() {
    m Classifier = new weka.classifiers.trees.DecisionStump();
}
```

分类器也是用的 DecisionStump 算法,在 Adaboost 篇里已经提过它是什么了。 接下来是 buildClassifier 函数:

```
public void buildClassifier(Instances instances) throws Exception {
   if (!(m Classifier instanceof WeightedInstancesHandler)) {
       throw new IllegalArgumentException("Classifier must be a "
              + "WeightedInstancesHandler!");
   // can classifier handle the data?
   getCapabilities().testWithFail(instances);
   // remove instances with missing class
   instances = new Instances(instances);
   instances.deleteWithMissingClass();
   // only class? -> build ZeroR model
   if (instances.numAttributes() == 1) {
       m ZeroR = new weka.classifiers.rules.ZeroR();
       m ZeroR.buildClassifier(instances);
      return;
   } else {
       m ZeroR = null;
   m Train = new Instances(instances, 0, instances.numInstances());
   m NNSearch.setInstances(m Train);
```

如果分类器不能利用样本权重,那么抛出异常,后面的代码会解释这个原因的。再下面是将所有的样本都默认为是训练样本,m\_NNSearch可以看一下我(Koala++)写《Weka 开发[18]——寻找 K 个邻居》,

```
public void updateClassifier(Instance instance) throws Exception {
   if (m_Train == null) {
```

```
throw new Exception("No training instance structure set!");
} else if (m Train.equalHeaders(instance.dataset()) == false) {
    throw new Exception("Incompatible instance types");
}
if (!instance.classIsMissing()) {
    m NNSearch.update(instance);
    m Train.add(instance);
}
```

LWL 实现了 UpdatableClassifier,表示它是可以增量学习的,其实也不太是那么回事感觉。 m\_NNSearch.update 还牵扯了一大堆代码,这里先不说了,以后看距离类的时候再看。

再下面是 distributionForInstance, 把这个函数拆开来看:

```
m NNSearch.addInstanceInfo(instance);
int k = m Train.numInstances();
if ((!m UseAllK && (m kNN < k))
        && ! (m WeightKernel == INVERSE || m WeightKernel == GAUSS)) {
    k = m kNN;
}</pre>
```

如果不是用全部的数据,并且 k 已经大于指定的样本数,不是用下面两个加权方法,就将 k 指定为用户指定的样本数。

```
Instances neighbours = m NNSearch.kNearestNeighbours(instance, k);
double distances[] = m NNSearch.getDistances();

// IF LinearNN has skipped so much that <k neighbours are remaining.
if (k > distances.length)
    k = distances.length;
```

kNearestNeighbours 是得到 instance 的 k 个邻居,而 getDistances 是 Returns the distances of the k nearest neighbours. The kNearestNeighbours or nearestNeighbour needs to be called first for this to work. (返回 k 个邻居的距离。需要先调用 kNearestNeighbours 或是 nearestNeighbour),简单地说,就是这个函数设计的不好,因为类用户要知道调用顺序。下面是如果 LinearNN 跳的过多了,那么只是小于 K 个邻居了,这里就是上面那个函数的作用。

```
// Determine the bandwidth
double bandwidth = distances[k - 1];

// Check for bandwidth zero
if (bandwidth <= 0) {
    // if the kth distance is zero than give all instances the same
    // weight
    for (int i = 0; i < distances.length; i++)
        distances[i] = 1;
} else {
    // Rescale the distances by the bandwidth
    for (int i = 0; i < distances.length; i++)
        distances[i] = distances[i] / bandwidth;
}</pre>
```

下面是就是确定范围,如果 bandwidth=0 当然就是所有的样本和要分类的样本是在一起的,那么所有的距离都是 1。否则就将它们变换到 (0,1)区间里。

```
// Pass the distances through a weighting kernel
for (int i = 0; i < distances.length; i++) {
    switch (m WeightKernel) {
    case LINEAR:
        distances[i] = 1.0001 - distances[i];
        break;</pre>
```

将距离通过一个加权的核,这是一个很有意思的东西,可以看一下 pattern recognition and machine learning 的 2.5 节,简单地说就是 k 近邻是在空间中找目标样本的邻居,那也就是用邻居的数量,来确定了这个样本邻居所在的子空间大小,而核是在目标样本周围划出来一个子空间,用它来确定样本邻居的数量。

常用的是 GAUSS,可以去笨笨的日志中找《关于 LWL (Local weighting Learning )的一些问题》这一篇看一下。

```
// Set the weights on the training data
double sumOfWeights = 0, newSumOfWeights = 0;
for (int i = 0; i < distances.length; i++) {</pre>
   double weight = distances[i];
   Instance inst = (Instance) neighbours.instance(i);
   sumOfWeights += inst.weight();
   newSumOfWeights += inst.weight() * weight;
   inst.setWeight(inst.weight() * weight);
   // weightedTrain.add(newInst);
// Rescale weights
for (int i = 0; i < neighbours.numInstances(); i++) {</pre>
   Instance inst = neighbours.instance(i);
   inst.setWeight(inst.weight() * sumOfWeights / newSumOfWeights);
// Create a weighted classifier
m Classifier.buildClassifier(neighbours);
// Return the classifier's predictions
return m Classifier.distributionForInstance(instance);
```

将这些目标样本的邻居设置新的权重,再 rescale,LWL 与别的分类器的区别就是它通过邻居来训练并且考虑邻居的距离,再下来就是调用基分类器的 distributionForInstance。